

毛楹智

✉ 15738183237@163.com · 📞 157-3818-3237 · 🗣️ Ssyllzz · 🌐 SsillyZz

🎓 教育背景

中国科学院软件研究所，计科硕士在读 中文信息处理实验室 2024.09 – 预计 2027.06
主要研究方向：LLMs、Safety Alignment、Post-Train 导师：韩先培研究员、孙乐研究员
郑州大学，计算机科学与技术学士 2020.09 – 2024.06

🔬 科研经历

LRMs 安全对齐：Self-Jailbreak 诊断与防御 (第一作者, ACL 2026) 2025.04 – 2026.01

- 分析大推理模型在多步推理中的安全失效问题，提出 Self-Jailbreak 现象：模型虽能在早期识别风险，但会在后续推理中自行推翻原有安全判断。基于这一发现，构建三阶段推理分析框架，并利用模型对原始推理轨迹进行自修正，生成安全对齐数据，避免对整条推理链施加过于粗粒度的干预。
- 提出 Chain-of-Guardrail 轨迹级训练框架，通过对导致不安全输出的推理步骤进行重写或回溯修正，在不破坏原有推理链的前提下提升模型安全性；在 Qwen3-32B 上将 ASR 从 39.49 降至 6.08，推理平均分仅由 85.78 下降至 84.91，整体优于强基线 SafeKey (ASR=9.61, Reasoning=75.0)。

LLM 自动化对齐训练框架 (核心贡献者, ACL 2025 System Demonstrations) 2024.09 – 2025.02

- 在自动化对齐框架中实现 CAI、Self-Rewarding 等自提升方法，基于模型自生成与自反馈构造对齐数据并完成训练闭环，从而在低标注条件下实现有效对齐。
- 主导 AutoAlign 自动化评测流程的构建，设计配置驱动的多基准评测 pipeline，打通 CLI 调度、OpenCompass 调用与结果聚合流程，实现对齐方法的统一评测接口与系统化对比分析。

DeepResearch 安全评测基准 (第一作者, Ongoing Research) 2026.01 – 至今

- 研究背景：针对 DeepResearch 在真实互联网环境下评测不可复现的问题，分析动态网页内容与检索路径变化对安全评测稳定性的影响，指出传统在线评测难以支撑复杂检索场景下的安全研究。
- 研究方法：构建离线评测系统，设计网页采集与 URL 重定向 pipeline，实现网页映射与检索轨迹复现，并搭建静态检索沙盒用于分析 DeepResearch 系统的安全风险。

🔧 项目经历

PPTAgent (核心贡献者) 2026.01 – 2026.03

- 负责 PPTAgent 训练数据生成与清洗流程搭建：围绕整体风格、页面内容、页数约束等 6 类排版约束构造端到端训练样本，并在采样阶段引入 Vision-based Oversight + Critic-Follow 双层质量控制机制，结合状态回溯过滤低质量轨迹，提升训练数据一致性与可用性。
- 基于 Qwen3.5-9B 进行 51K 长上下文 SFT，针对超长输入场景通过并行训练与梯度检查点优化显存占用，解决训练过程中的 OOM 问题并提升收敛稳定性；最终在 PPTEval 上取得 4.19 分，接近 GPT-5 的 4.22 分表现。

基于强化学习的 AIGC 内容安全审核模型 (项目负责人) 2025.11 – 至今

- 面向复杂语境与隐喻表达场景，构建通用 Harm 与垂直业务双域训练数据，并分别设计 Prompt/CoT 冷启动样本；结合生成式难例扩增补齐长尾风险分布，提升模型对隐晦违规内容的识别能力。
- 针对敏感度提升引发的 AIGC 任务过度拒绝问题，设计基于 GRPO 的非对称条件奖励体系。将格式奖励受控于正确性门槛并辅以规范拒答奖励；同时构建非对称惩罚网络以修正期望收益偏差，最终在测试集上取得 Accuracy / Recall / F1 达 95.16% / 93.50% / 92.06% 的表现。

🔧 专业技能

- 大模型后训练与对齐：具备大模型后训练与对齐能力，熟悉 Transformer 架构，具备自生成数据构造与难例扩增经验，能够完成从数据生成到模型训练与评测的闭环优化。
- 评测与系统能力：熟练使用 Python 与 Linux，具备大模型基准测试与评测流程设计经验，能够基于多轮实验进行模型效果分析与对比，并支持评测驱动模型迭代优化。